模式识别与机器学习作业

基于 SVM 的二分类算法实现与评估

姓名 简雯慧

学号 62123104

专业 未来机器人

2026 年 4 月 3 日

目录

1 选题背景 **3**

2 算法描述 **3**

3 软件实现 **3**

4 数据分析和可视化 **4**

4.1 初始模型与问题发现 4

4.2 模型优化与对比分析 4

5 结论 **6**

1 选题背景

本报告旨在通过分析葡萄牙某银行机构的电话直销活动数据，预测客户是否会订阅定期存款（即变量 y）。在模式识别与机器学习领域，这属于典型的二元分类任务。建立精准的预测模型能够帮助金融机构更有针对性地筛选潜在客户，从而降低营销成本并提高活动成功率 [MCR14]。

根据作业要求，需要从感知机、Fisher 线性判别分析（LDA）和支持向量机（SVM）中选择算法进行实现。鉴于支持向量机在处理非线性关系和高维数据特征时表现出色，本实验选择采用 SVM 算法完成该分类任务，并预期通过核技巧实现对客户订阅意愿的有效划分。

2 算法描述

本报告采用支持向量机（Support Vector Machine, SVM）算法。SVM 的基本模型是定义在特征空间上的间隔最大的线性分类器。其核心思想是找到一个超平面，将不同类别的样本分离开来，并使得离超平面最近的样本点（支持向量）到超平面的距离最大化。

对于给定的二分类数据集，线性可分 SVM 的优化目标可以表示为如下凸二次规划问题：

$$\min_{w,b} \frac{1}{2}||w||^2 \tag{1}$$

约束条件为 $y_i(w^T x_i + b) \geq 1$。

由于实际的银行营销数据往往存在噪声且不是完全线性可分的，通常会引入松弛变量 $\xi_i \geq 0$ 和惩罚参数 C，转化为软间隔最大化问题：

$$\min_{w,b,\xi} \frac{1}{2}||w||^2 + C\sum_{i=1}^{N} \xi_i \tag{2}$$

为了处理数据中的非线性分类边界，本实验采用了核技巧（Kernel Trick）。通过非线性映射将输入空间的数据映射到高维特征空间。实验中选用了最常用的径向基核函数（RBF 核）：

$$K(x_i, x_j) = \exp(-\gamma||x_i - x_j||^2) \tag{3}$$

模型训练完成后，对于新的输入样本，通过计算决策函数来输出预测的类别标签。

3 软件实现

本实验采用 Python 语言进行开发。代码中主要使用了 `pandas` 进行表格数据的读取与处理，使用 `scikit-learn` 用于数据预处理、模型构建与评估，以及 `matplotlib` 和 `seaborn` 用于结果可视化。

具体的软件实现流程如下：

- **数据读取与编码**：使用 `pandas` 读取 `bank.csv` 数据。遍历数据集各列，利用 `LabelEncoder` 将 `object` 类型的字符串特征（如职业、教育水平等）统一编码为数值型。
- **数据划分与标准化**：将目标标签 `y` 剥离形成特征矩阵 X。按 8:2 的比例划分训练集与测试集后，引入 `StandardScaler` 对特征矩阵进行零均值单位方差标准化，避免距离度量被量级较大的特征主导。
- **模型训练与预测**：实例化 `SVC` 分类器并指定 `kernel='rbf'`。针对数据集中订阅与未订阅样本比例严重失衡的问题，引入 `class_weight='balanced'` 参数。最后，在测试集上输出预测标签，并使用 `decision_function` 获取决策分数用于绘制 ROC 曲线。

4 数据分析和可视化

本实验使用的是包含 4521 个样本的 `bank.csv` 数据集，每个样本具有 16 个输入特征和 1 个二元目标变量。在模型优化过程中，本实验对比了不同预处理策略对模型性能的影响。

4.1 初始模型与问题发现

在初步构建 SVM 模型时（未进行特征缩放与类别权重调整），混淆矩阵显示模型整体准确率高达约 89%，但对正例（类别 1，订阅客户）的预测数量（True Positive）为 0，ROC 曲线下面积（AUC）仅为 0.71。这表明高准确率完全是由数据极度不平衡（多数类为不订阅客户）导致的假象，模型实际上陷入了多数类陷阱，缺乏实际业务价值。

4.2 模型优化与对比分析

针对上述问题，本实验引入了特征标准化（`StandardScaler`）与类别权重平衡（`class_weight='balanced'`）。优化后的模型性能表现出了本质的提升。如图 2所示，特征标准化有效释放了 RBF 核函数在高维空间中的线性可分能力，模型的 AUC 值从 0.71 跃升至 0.88。

如图 4所示，在引入 `balanced` 参数后，模型成功打破了“全零预测”的僵局，能够有效识别出真正的潜在订阅客户（左下角漏报数量减少，右下角真正例增加）。

需要指出的是，该优化策略导致模型整体准确率小幅下降了约 4%，且假正例（FP）有所增加。这是因为模型加重了对少数类的关注，预测倾向变得激进。但在银行直销场景下，漏掉一个潜在客户的机会成本远高于拨打一个无效推销电话的成本，因此牺牲部分整体准确率换取少数类召回率的提升，是符合商业逻辑的合理折中。

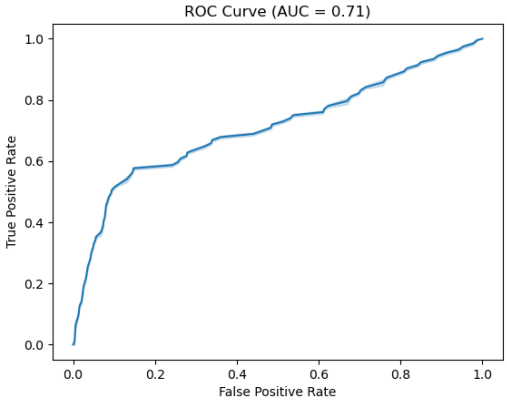

图 1: 优化前的 ROC 曲线

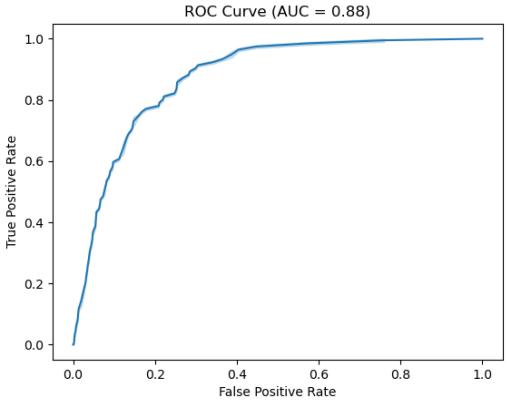

图 2: 优化后的 ROC 曲线

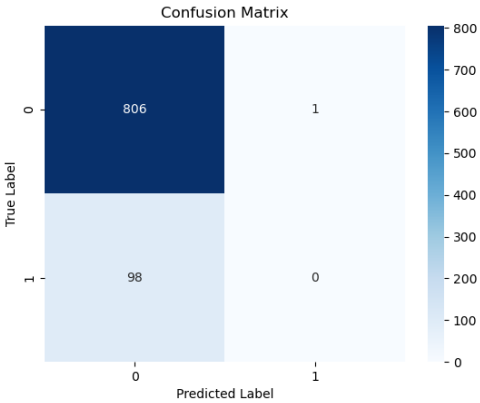

图 3: 优化前的混淆矩阵

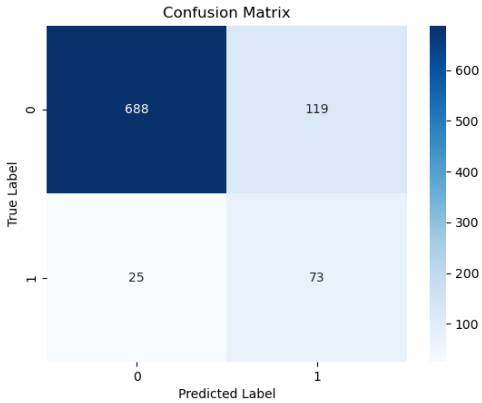

图 4: 优化后的混淆矩阵

5 结论

本次作业使用 Python 实现了基于 RBF 核的支持向量机（SVM）算法，对银行电话营销数据进行了分类预测分析。

实验结果表明，在处理包含连续型与分类型混合且类别极度不平衡的真实金融数据时，常规模型容易产生“高准确率假象”。通过引入特征标准化和类别权重平衡机制，改进后的模型 AUC 达到了 0.88，成功实现了对少数类（订阅客户）的有效捕捉，具备了一定的实际应用价值。

本实验的局限性在于特征处理方式较为基础，`LabelEncoder` 可能会对无序离散特征引入不合理的数值大小关系。未来的改进方向可考虑对无序分类变量采用独热编码（One-Hot Encoding），并通过网格搜索（GridSearchCV）对核参数 γ 及惩罚系数 C 进行进一步调优。

References

[MCR14] Sérgio Moro, Paulo Cortez, and Paulo Rita. “A data-driven approach to predict the success of bank telemarketing”. In: *Decision Support Systems* 62 (2014), pp. 22–31.