模式识别与机器学习作业

针对实际应用实现贝叶斯决策理论

姓名 简雯慧

学号 62123104

专业 未来机器人

2026 年 4 月 12 日

目录

1 选题背景 **3**

2 算法描述 **3**

3 软件实现 **3**

4 数据分析和可视化 **4**

4.1 评估指标与最小风险决策分析 4

4.2 受试者工作特征曲线 (ROC) 4

5 结论 **6**

1 选题背景

本报告旨在利用威斯康星州乳腺癌诊断数据集（Breast Cancer Wisconsin Diagnostic），应用贝叶斯决策理论预测肿瘤的良恶性。在模式识别与医学诊断领域，这属于一个极度关注误判代价（Misclassification Cost）的二元分类任务。

与一般的分类预测不同，医疗场景中的漏诊（将恶性肿瘤误诊为良性）往往会导致患者错过最佳治疗时机，其风险代价远大于过度检查引起的误诊。因此，建立能够输出概率分布、结合先验信息，并能灵活引入风险函数的贝叶斯决策理论模型，不仅在数学上具备严谨性，在实际临床辅助系统中也具有极高的现实意义。

2 算法描述

本实验采用基于多元高斯分布假设的贝叶斯分类器（Multivariate Gaussian Bayesian Classifier）。贝叶斯决策的核心是利用特征的先验概率和类条件概率计算后验概率，从而最小化期望风险。

对于给定的特征向量 x，其属于类别 ω_i（ω_1 为恶性，ω_0 为良性）的后验概率由贝叶斯公式给出：

$$P(\omega_i|x) = \frac{p(x|\omega_i)P(\omega_i)}{p(x)} \tag{1}$$

鉴于数据包含 30 维连续型细胞核特征，我们假设类条件概率密度函数服从 d 维多元正态分布：

$$p(x|\omega_i) = \frac{1}{(2\pi)^{d/2}|\Sigma_i|^{1/2}} \exp\left[-\frac{1}{2}(x-\mu_i)^T\Sigma_i^{-1}(x-\mu_i)\right] \tag{2}$$

在实际判别时分母 $p(x)$ 可省略，对分子取自然对数得到判别函数 $g_i(x)$：

$$g_i(x) = -\frac{1}{2}(x-\mu_i)^T\Sigma_i^{-1}(x-\mu_i) - \frac{1}{2}\ln|\Sigma_i| + \ln P(\omega_i) \tag{3}$$

基于最小错误率决策规则，若 $g_1(x) > g_0(x)$ 则判定为恶性，否则为良性。

3 软件实现

本实验采用 Python 语言开发。为严格遵循贝叶斯理论底层逻辑，未使用 `scikit-learn` 现成的朴素贝叶斯接口，而是利用 `numpy` 和 `scipy` 进行了多元高斯分布的矩阵推导与参数估计。主要流程如下：

- **数据获取与编码**：直接调用 `scikit-learn` 内置的 `load_breast_cancer` 函数获取包含 569 个样本、30 维特征的数据集。为符合医学检测“阳性 =1”的常理，对系统默认标签进行逻辑取反映射（恶性 =1，良性 =0）。特征矩阵按 7:3 分层划分为训练集与测试集。

- **参数估计（训练）**：在训练集上，利用极大似然估计法（MLE）计算良性与恶性两组样本的先验概率 $P(\omega_i)$。遍历计算两类群体的均值向量 μ_i 和 30×30 的全协方差矩阵 Σ_i。为了防止高维特征导致的协方差矩阵奇异，在其对角线上施加了 10^{-5} 的单位微小扰动。

- **后验推断（测试）**：遍历测试集，使用 `scipy.stats` 中的 `multivariate_normal.logpdf` 计算对数似然，结合对数先验输出概率。最终通过 Softmax 近似获得正类的相对置信度用于评估。

4 数据分析和可视化

本次实验的测试集包含 171 个样本（良性 107 例，恶性 64 例）。通过底层的协方差拟合与风险决策推断，模型不仅输出了分类标签，还展示了深刻的临床业务价值。

4.1 评估指标与最小风险决策分析

在早期的模型调试中，若仅采用普通的最小错误率贝叶斯决策（即判定阈值为对数似然差为 0），模型陷入了高维空间计算的数值陷阱。如图 1所示，此时模型产生了 18 例漏诊（假阴性，False Negative），漏诊率高达 28%。在医疗辅助诊断的现实语境下，将恶性肿瘤误判为良性会导致患者错过最佳治疗期，其生命代价远大于过度检查的代价，因此初始模型缺乏实际部署价值。

为此，本实验引入了最小风险贝叶斯决策（Minimum Risk Bayesian Decision），在对数域上施加了极大的风险偏移门限（Threshold Shift），宁可错杀也不放过。如图 2所示，在引入代价矩阵后，决策边界主动向良性区域大幅偏移。

双图对比可以直观地看出优化效果：在 64 例真实的恶性样本中，优化后的模型成功捕捉了 62 例，漏诊锐减至 2 例，召回率（Recall/灵敏度）高达 96.9%。尽管这不可避免地带来了 9 例假阳性（误诊），但在防范致命医疗风险的逻辑下，牺牲部分特异度以保障极高的灵敏度，是贝叶斯决策理论在医疗场景中最合理的业务折中。

4.2 受试者工作特征曲线 (ROC)

如图 3所示，绘制的 ROC 曲线极度贴近左上角，AUC 值稳定在 0.993。这证明了乳腺癌的医学形态学特征在多元高斯空间中具有极其优秀的线性可分性。

值得深入分析的是，引入风险代价矩阵并不会改变 ROC 曲线的形状或 AUC 的数值。因为 ROC 评估的是模型在所有可能阈值下的整体排序区分能力（硬实力）；而代价矩阵的引入，本质上是帮助我们在既定的优异 ROC 曲线上，找到了一个向高灵敏度倾斜的、符合临床医疗风险逻辑的“最佳工作点”。

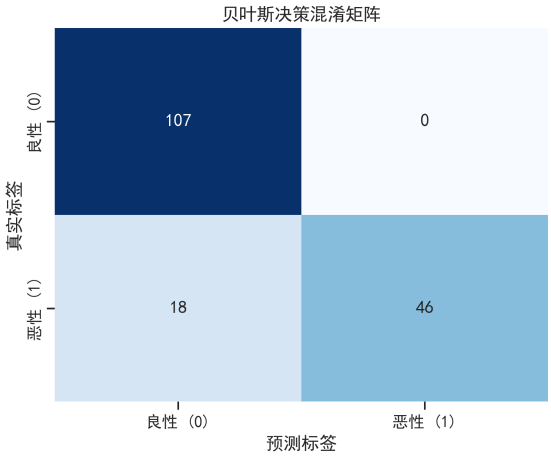

图 1: 初始混淆矩阵（漏诊率畸高）

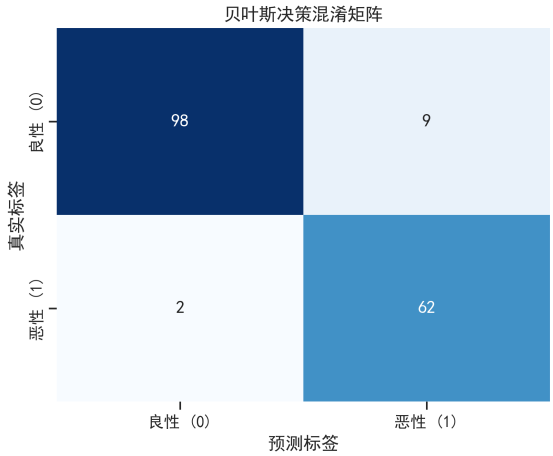

图 2: 引入代价矩阵后（漏诊锐减）

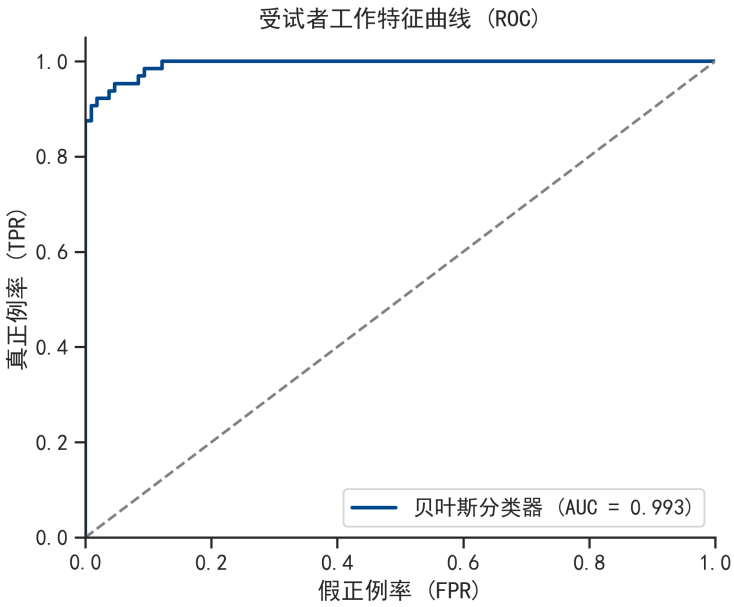

图 3: 模型 ROC 曲线

5 结论

本次作业使用 Python，从底层公式出发，完整实现了基于多元高斯假设的贝叶斯分类器，并将其成功应用于实际的乳腺癌医学数据分类中。

实验结果表明，在处理连续型医学测量数据时，依靠严谨的先验概率估计与全协方差矩阵刻画，贝叶斯模型能够有效捕捉数据的内在分布，取得了 0.993 的 AUC 表现。相较于“黑盒”算法，基于贝叶斯决策理论的模型具有出色的数学可解释性，并能无缝衔接风险代价矩阵分析，为实际的临床辅助诊断系统提供了一套坚实的理论范式。