模式识别与机器学习作业

群智能优化算法（ACO）的实际应用

姓名 简雯慧

学号 62123104

专业 未来机器人

2026 年 4 月 27 日

目录

1 选题背景与问题定义 **3**

2 算法描述 **3**

2.1 状态转移规则 (路径选择) 3

2.2 信息素更新规则 3

3 软件实现 **4**

4 数据分析与结果可视化 **4**

4.1 算法收敛性分析 4

4.2 最优物理路径展示 5

4.3 算法启发式特征与随机性分析 5

5 结论 **6**

1 选题背景与问题定义

随着现代物流与供应链的飞速发展，如何规划运输车辆的配送路线以最小化总成本，成为了学术界与工业界的核心痛点。本报告选取经典的“旅行商问题（Traveling Salesman Problem, TSP）”作为智能优化算法的实际应用场景。

具体应用场景定义为：一辆物流配送车从某中心城市出发，需要遍历中国 34 个主要省级行政区（省会及直辖市）进行货物配送，并且每个城市仅访问一次，最终返回起点。系统要求利用智能优化方法求解出总行驶距离最短的闭环最优路径。由于 34 个城市的排列组合空间高达 33!，属于典型的 NP-Hard 问题，传统的精确算法面临组合爆炸，因此采用仿生智能优化算法进行求解是最佳选择。

2 算法描述

本实验选用群智能优化算法中的代表——**蚁群优化算法（Ant Colony Optimization, ACO）**。ACO 通过模拟自然界蚂蚁在寻找食物过程中释放“信息素（Pheromone）”的行为，实现全局空间的最优解探索。

2.1 状态转移规则 (路径选择)

在第 t 次迭代中，蚂蚁 k 位于城市 i，它选择移动到未访问城市 j 的概率 $P_{ij}^k(t)$ 由信息素浓度和启发式距离共同决定：

$$P_{ij}^k(t) = \begin{cases} \frac{[\tau_{ij}(t)]^\alpha \cdot [\eta_{ij}]^\beta}{\sum_{l \in allowed_k} [\tau_{il}(t)]^\alpha \cdot [\eta_{il}]^\beta}, & \text{if } j \in allowed_k \\ 0, & \text{otherwise} \end{cases} \tag{1}$$

其中，$\tau_{ij}(t)$ 是边 (i,j) 上的信息素浓度；$\eta_{ij} = 1/d_{ij}$ 是启发式因子（距离的倒数）；α 为信息素重要程度；β 为启发式因子重要程度；$allowed_k$ 是蚂蚁 k 尚未访问的城市集合。

2.2 信息素更新规则

当所有蚂蚁完成一次完整的遍历后，所有路径上的信息素会发生挥发，同时蚂蚁会在它们走过的路径上释放新的信息素。全局信息素更新公式为：

$$\tau_{ij}(t+1) = (1-\rho)\tau_{ij}(t) + \Delta\tau_{ij} \tag{2}$$

$$\Delta\tau_{ij} = \sum_{k=1}^{M} \Delta\tau_{ij}^k \tag{3}$$

其中，$\rho \in (0,1)$ 是信息素挥发系数；M 是蚂蚁总数。蚂蚁 k 在边 (i,j) 上释放的信息素 $\Delta\tau_{ij}^k$ 通常采用 Ant-Cycle 模型，即 $\Delta\tau_{ij}^k = Q/L_k$，其中 Q 是常数，L_k 是蚂蚁 k 走过的路径总长度。总长度越短，释放的信息素越多，从而形成正反馈。

3 软件实现

本实验采用 Python 语言开发。

- **数据准备**：内置中国 34 个核心城市的经纬度坐标，通过 `numpy.linalg.norm` 构建欧氏距离矩阵。
- **算法参数**：设定蚂蚁群体规模 $N_{ants} = 80$，最大迭代次数 $Iter = 200$，信息素因子 $\alpha = 1.0$，启发式因子 $\beta = 5.0$，挥发系数 $\rho = 0.1$。
- **并行模拟**：通过双层循环实现多只蚂蚁的独立寻路，利用轮盘赌算法（Roulette Wheel Selection）实现状态转移概率的随机选择，从而有效避免算法过早陷入局部最优。

4 数据分析与结果可视化

4.1 算法收敛性分析

图 1 展示了 ACO 算法在求解该 34 城市 TSP 问题时的收敛曲线。可以看出，在迭代初期，由于信息素分布均匀，蚂蚁探索的随机性较强，最优距离下降极其迅速；在迭代中后期，随着短路径上信息素的正反馈积累，算法逐渐收敛并找到了全局较优解，体现了蚁群算法极其优秀的收敛效率。

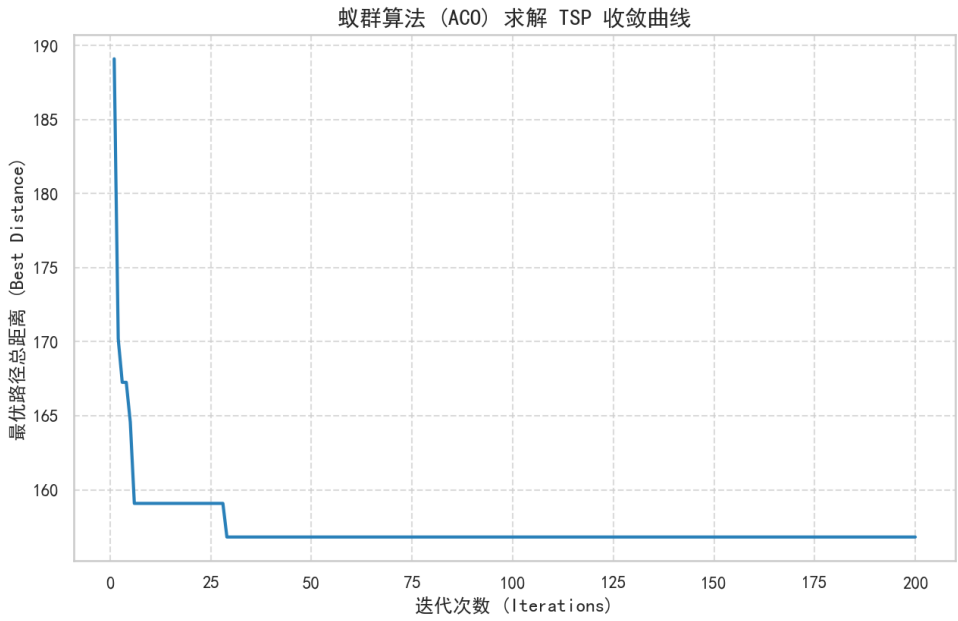

图 1: 蚁群算法优化 TSP 的距离收敛曲线

4.2 最优物理路径展示

图 2 将算法搜索出的最优结果映射回了真实的地理坐标系中。图中各点代表 34 个主要城市，蓝色的五角星代表物流起止枢纽。从连线拓扑图可以看出，ACO 生成的路径呈现出极其整洁的多边形闭环，没有出现严重的交叉与折返现象（避免交叉是 2D-TSP 最优解的重要几何特征）。这在工程实际上证明了该路线具有极高的燃油经济性和时间效率。

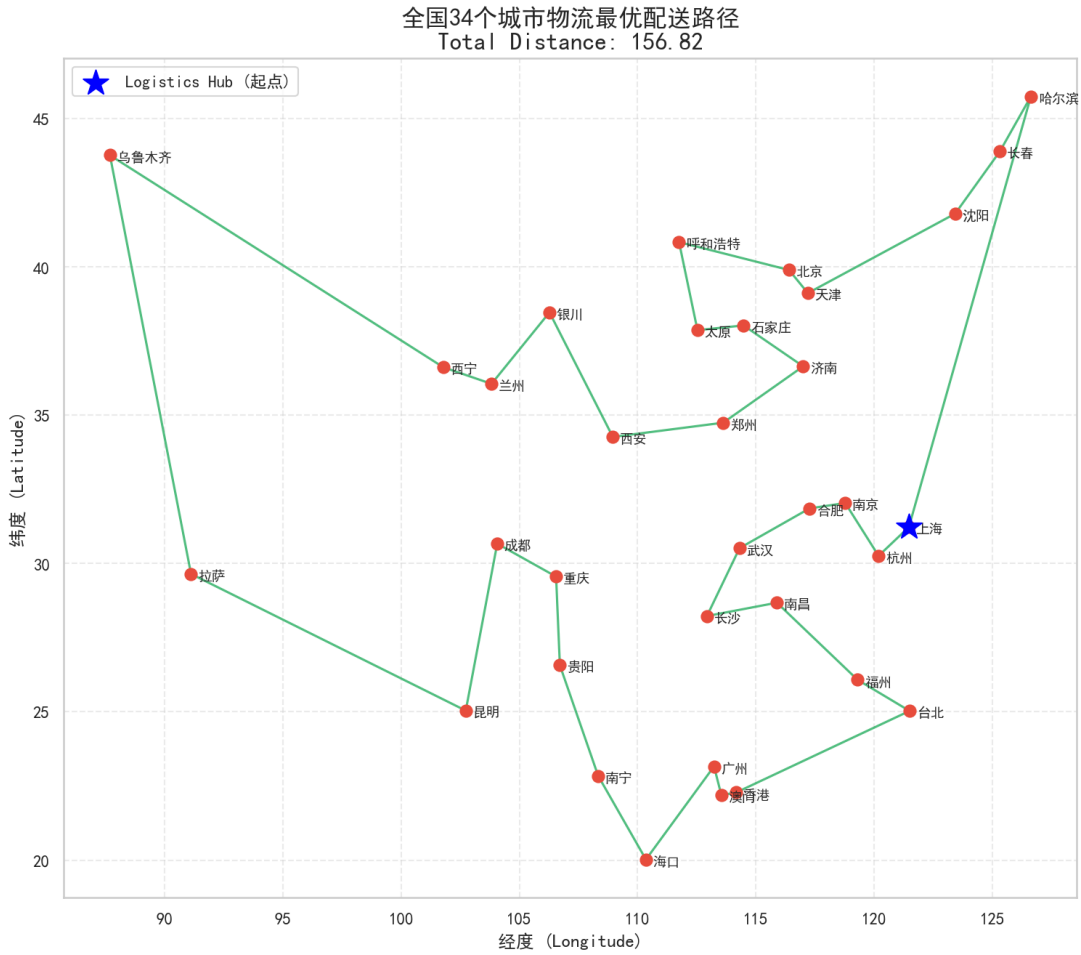

图 2: 基于 ACO 优化的全国 34 城市最优物流闭环路线图

4.3 算法启发式特征与随机性分析

在代码调试过程中观察到：如果不固定随机数种子，算法每次运行得到的最优路径和总距离都会存在微小差异。经过理论分析，这种现象并非系统误差，而是由智能优化算法的“启发式随机搜索（Stochastic Heuristic Search）”本质决定的，主要归结于以下两点：

- **状态转移的概率性（Exploration 机制）**：蚁群算法在路径选择阶段采用了基于信息素的轮盘赌选择机制（Roulette Wheel Selection）。这种随机性设定是有意为之

的，它确保了蚂蚁群体具备探索未知解空间的能力，避免算法过早陷入局部死胡同。

- **庞大解空间与局部最优陷阱（Local Optima）**：34 个城市的 TSP 问题解空间规模高达 33!。在有限的迭代次数与种群规模下，算法极大概率是收敛于全局最优解附近的高质量“局部最优解”。

5 结论

本报告针对实际物流调度中的复杂路线规划需求，成功利用群智能优化算法（蚁群算法）进行了建模与求解。实验表明，将基于群体协作与信息素正反馈的自然机制引入复杂工程计算，能够以极小的算力成本高效穿透 NP-Hard 问题的庞大搜索空间。相比于传统的经验规划法，该智能算法为现代物流系统提供了科学的量化决策支持。在实验过程中